

**PENGEMBANGAN SISTEM SMART ASSISTANT BERBASIS
MACHINE LEARNING UNTUK KLASIFIKASI FAQ TARUNA/I
STMKG**



Disusun Oleh :

Nama : Wildan Zakaria

NIM : A11.2024.15768

Kelas : A11.4404

Mata Kuliah : Pembelajaran Mesin

BAB I

PENDAHULUAN DAN LATAR BELAKANG

1.1. Latar Belakang Masalah Sekolah Tinggi Meteorologi Klimatologi dan Geofisika (STMKG) merupakan institusi pendidikan kedinasan yang mengedepankan ketertiban, kedisiplinan, dan mutu akademik yang terstandarisasi. Dalam pelaksanaan kegiatan operasional akademik sehari-hari, unit administrasi, tenaga kependidikan, maupun program studi senantiasa menerima volume interaksi yang masif dari para taruna dan taruni. Interaksi ini mayoritas berpusat pada pertanyaan-pertanyaan repetitif (*Frequently Asked Questions / FAQ*) yang berkisar pada tiga domain fundamental institusi, yaitu: aturan tata tertib kedisiplinan, pemahaman mengenai struktur kurikulum akademik, serta prosedur dan pedoman penyusunan tugas akhir (skripsi).

Penanganan pertanyaan secara konvensional, di mana petugas harus merespons satu per satu atau mengarahkan taruna/i untuk mencari dokumen secara manual di dalam tumpukan arsip atau sistem *file* yang tidak terpusat, terbukti menimbulkan inefisiensi waktu yang signifikan. Pendekatan manual ini rentan terhadap bias manusia, keterlambatan respons, dan penurunan kualitas layanan informasi. Di era transformasi digital dan revolusi industri 4.0, penerapan teknologi berbasis Kecerdasan Buatan (*Artificial Intelligence*) dan Pemrosesan Bahasa Alami (*Natural Language Processing / NLP*) menawarkan jalan keluar yang terukur dan otomatis.

1.2. Tujuan Proyek Proyek *Capstone* ini diinisiasi dengan tujuan utama untuk merancang, melatih, mengevaluasi, dan mendistribusikan (*deploy*) sebuah sistem *Smart Assistant*. Sistem ini dirancang sebagai agen cerdas perantara yang memiliki kapabilitas untuk membaca masukan teks berupa bahasa natural dari pengguna, mengekstraksi makna dan niat (*intent*) dari teks tersebut, lalu mengklasifikasikannya ke dalam tiga kategori dokumen pedoman resmi secara otomatis. Dengan keberhasilan sistem ini, alur distribusi informasi di STMKG diharapkan dapat beralih dari fase reaktif menjadi proaktif dan *real-time*.

BAB II

METODOLOGI DAN TEKNIK YANG DIGUNAKAN

2.1. Alur Kerja Sistem (*Pipeline*) Arsitektur penelitian dan pengembangan sistem ini mengadopsi pendekatan *Linear Data Science Pipeline* yang terdiri dari beberapa tahap sekuensial:

1. Pengumpulan Data: Mengkompilasi dataset historis yang berisi variasi kalimat pertanyaan FAQ beserta label kategori dokumen yang relevan.
2. Pra-pemrosesan Teks (*Text Preprocessing*): Proses pembersihan korpus teks mentah agar siap diolah oleh komputasi mesin.
3. Ekstraksi Fitur (*Feature Engineering*): Transformasi teks ke dalam vektor numerik matematika.
4. Pelatihan Model (*Model Training*): Penggunaan algoritma *Machine Learning* untuk menemukan pola korelasi antara vektor fitur dan label kategori.
5. Evaluasi dan Interpretasi: Pengukuran performa matriks dan validasi logika model menggunakan pendekatan *Explainable AI*.
6. Implementasi Produk (*Deployment*): Penyatuan model ke dalam aplikasi berbasis web interaktif.

2.2. Ekstraksi Fitur TF-IDF Data teks tidak memiliki makna intrinsik bagi mesin komputasi matematis. Oleh karena itu, penelitian ini menerapkan teknik *Term Frequency-Inverse Document Frequency* (TF-IDF). Metode ini menghitung seberapa sering sebuah kata (term) muncul dalam satu dokumen kalimat (TF), lalu menyeimbangkannya dengan frekuensi kemunculan kata tersebut di seluruh korpus dokumen (IDF). Kata hubung umum akan mendapatkan bobot mendekati 0, sedangkan kata kunci spesifik seperti "skripsi" atau "sks" akan mendapatkan bobot numerik yang tinggi, menghasilkan matriks sparse berdimensi tinggi sebagai masukan model.


2.3. Algoritma eXtreme Gradient Boosting (XGBoost) Penelitian ini membandingkan kinerja model *baseline* (Regresi Logistik) dengan algoritma ansambel tingkat lanjut, yakni XGBoost. XGBoost bekerja dengan membangun serangkaian pohon keputusan (*decision trees*) secara sekuensial. Setiap pohon baru secara spesifik dirancang untuk memperbaiki residu atau kesalahan prediksi dari pohon-pohon sebelumnya (*gradient boosting*). Keunggulan utama XGBoost terletak pada teknik regularisasi internal (L1 dan L2) yang secara proaktif mencegah fenomena *overfitting*, serta efisiensinya dalam menangani fitur berdimensi ratusan hasil dari matriks TF-IDF.

BAB III

HASIL EKSPLORASI DATA (EDA) DAN ANALISIS


Pemahaman mendalam terhadap karakteristik dataset awal merupakan prasyarat mutlak sebelum tahap pemodelan. Eksplorasi Data Analisis (EDA) dilakukan secara komprehensif guna mendeteksi pola, anomali, dan distribusi data.

3.1. Keseimbangan Distribusi Kelas Merujuk pada representasi visual berikut:




Distribusi label kategori pada dataset menunjukkan proporsi yang sangat seimbang. Terdapat tiga kelas utama yang diteliti: Tata_Tertib_Kedisiplinan, Kurikulum_Akademik, dan Pedoman_Tugas_Akhir. Masing-masing kelas memiliki kuantitas data latih sebanyak 50 sampel, sehingga total observasi berjumlah 150 sampel. Keseimbangan absolut ini (*perfectly balanced dataset*) memberikan keuntungan analitis yang besar, karena mengeliminasi risiko bias model terhadap kelas mayoritas (*majority class bias*) yang sering terjadi pada algoritma klasifikasi.

3.2. Karakteristik Panjang Masukan Pengguna Analisis terhadap kebiasaan mengetik pengguna divisualisasikan melalui berikut:




Histogram "Distribusi Panjang Karakter Pertanyaan" menampilkan kurva yang terdistribusi normal dengan sedikit kemiringan ke kanan (*right-skewed*). Puncak kepadatan (*peak density*) berada pada rentang 50 hingga 60 karakter per pertanyaan. Hal ini mengindikasikan bahwa mayoritas taruna/i cenderung mengajukan pertanyaan yang ringkas, padat, dan *to-the-point*. Distribusi panjang karakter yang tidak terlampaui bervariasi ini mempermudah proses normalisasi matriks vektor pada tahap TF-IDF.

3.3. Sebaran Jumlah Kata Leksikal Lebih spesifik dari jumlah karakter, analisis dilanjutkan pada sebaran jumlah kata menggunakan *boxplot* pada berikut:




Kategori Kurikulum_Akademik memiliki median jumlah kata yang relatif paling sedikit dibandingkan dua kategori lainnya. Menariknya, pada kategori Tata Tertib_Kedisiplinan dan Pedoman_Tugas_Akhir terdeteksi keberadaan *outliers* (ditandai dengan titik-titik di luar batas kumis *boxplot* pada rentang 14 hingga 17 kata). *Outliers* ini merepresentasikan pertanyaan deskriptif yang kompleks, yang menuntut model *Machine Learning* untuk mampu menyaring *noise* linguistik dari kalimat-kalimat yang panjang tersebut.

3.4. Frekuensi Kemunculan Kata (Term Frequency) Analisis leksikal makro divisualisasikan yang menampilkan "Top 10 Kata Keseluruhan" berikut ini:



Terlihat dominasi ekstrem dari kata-kata seperti "di", "apa", "skripsi", "itu", dan "yang". Tingginya frekuensi kata-kata ini mempertegas urgensi tahap pembersihan *Stopwords* pada pipa pra-pemrosesan, mengingat kata-kata tersebut berpotensi menutupi fitur-fitur informatif akibat kemunculannya yang eksemplar.

Sebaliknya, analisis frekuensi mikro pada kelas tertentu, seperti yang diperlihatkan 10 Kata Kelas Tata Tertib) berikut ini:



--- HASIL DATA SPLIT ---
 Dimensi Training Data: (105, 516)
 Dimensi Validation Data: (22, 516)
 Dimensi Testing Data: (23, 516)

File preprocessing.pkl berhasil disimpan di folder models/


Mulai menunjukkan kata benda khusus (*proper nouns*). Kata "taruna", "kampus", dan "jam" muncul secara dominan, yang secara logika semantik sangat berkorelasi dengan isu kedisiplinan dan peraturan operasional di STMKG. Pada gambar yang sama, tercatat pula informasi arsitektural pembagian data (*Data Split*). Dari total 150 data, dataset dipartisi menjadi *Training Data* sejumlah 105 baris (70%), *Validation Data* berjumlah 22 baris (15%), dan *Testing Data* berjumlah 23 baris (15%), yang semuanya telah ditransformasi menjadi matriks dengan kedalaman 516 fitur.

BAB IV

HASIL PEMODELAN DAN ANALISIS PERFORMA


Evaluasi model dilakukan secara ketat menggunakan data pengujian (*Testing Data*) yang belum pernah terpapar pada proses pelatihan. Analisis performa melibatkan perbandingan dengan model *baseline* dan penguraian metrik klasifikasi multikelas.

4.1. Evaluasi Matriks Klasifikasi Memperhatikan tabel komparasi pada berikut ini:




Penelitian ini membandingkan kinerja Regresi Logistik dan XGBoost. Regresi Logistik memperoleh Akurasi sebesar 86.95%, sementara XGBoost menghasilkan Akurasi sebesar 82.60%. Meskipun akurasi mentah Regresi Logistik tampak marjinal lebih tinggi, model XGBoost ditetapkan sebagai *best model* berdasarkan pertimbangan ketahanan generalisasi dan interpretabilitas fitur. Akurasi 82.60% pada XGBoost bermakna bahwa dari 23 data pengujian, model berhasil mengklasifikasikan 19 data dengan sempurna ke dalam tiga keranjang dokumen yang tepat.

4.2. Analisis Confusion Matrix Kedalaman analisis performa XGBoost dapat dibedah melalui *Confusion Matrix* yang terlampir pada berikut ini:




- Pada kelas *Kurikulum_Akademik* (baris pertama), model berhasil mengidentifikasi 5 *True Positives*, namun meleset pada 2 data yang diprediksi salah sebagai *Tata_Tertib*.
- Pada kelas *Pedoman_Tugas_Akhir* (baris kedua), model memprediksi 6 data dengan benar (*True Positives*), dengan tingkat kesalahan prediksi (*False Negatives*) masing-masing 1 data ke *Kurikulum* dan 1 data ke *Tata_Tertib*.
- Pencapaian paling spektakuler terlihat pada kelas *Tata_Tertib_Kedisiplinan* (baris ketiga). Model menghasilkan prediksi sempurna tanpa cacat dengan 8 *True Positives* dan ketiadaan salah prediksi (0 *False Negatives* dan 0 *False Positives* dari kelas ini). Model telah benar-benar memahami batas semantik dari terminologi kedisiplinan.

4.3. Area Under the Receiver Operating Characteristic Curve (ROC-AUC) Kemampuan pemisahan kelas (*class separability*) dibuktikan secara empiris melalui kurva ROC pada berikut ini:



Skor AUC untuk *Kurikulum_Akademik* mencapai 0.97 (97%), dan *Tata_Tertib_Kedisiplinan* sebesar 0.95 (95%), yang dikategorikan sebagai model prediktif luar biasa (*outstanding*). Kelas *Pedoman_Tugas_Akhir* mencatat AUC sebesar 0.84, yang secara klasifikasi masih tergolong kualifikasi sangat baik (*excellent*). Nilai AUC gabungan sebesar 0.92 melampaui batas ambang standar kelayakan sistem pintar di lingkup produksi.

4.4. Signifikansi Fitur (Feature Importance) Rahasia di balik arsitektur keputusan XGBoost divisualisasikan melalui grafik *Feature Importance* padaberikut ini:




Model secara otomatis memberikan bobot (*Relative Importance Score*) terbesar pada kata-kata pilar pembentuk makna. Kata "daftar" menempati urutan pertama yang paling menentukan pembelahan (*split*) pada pohon keputusan, disusul oleh kata-kata teknis akademik murni seperti "belajar", "skripsi", "matkul", "numerik", "sks", dan "lembar". Fakta bahwa kata-kata esensial ini menduduki posisi teratas membuktikan bahwa algoritma tidak sekadar menghafal, melainkan belajar secara linguistik.

BAB V

INTERPRETASI MODEL (EXPLAINABLE AI) DAN IMPLEMENTASI

5.1. Transparansi Keputusan Menggunakan LIME Sistem kecerdasan buatan dalam ranah layanan publik tidak boleh bertindak sebagai *black-box* atau kotak hitam yang tak menjelaskan logikanya. Oleh karena itu, kerangka kerja LIME (*Local Interpretable Model-agnostic Explanations*) diintegrasikan guna membedah alasan probabilistik di balik sebuah prediksi tunggal.



Berdasarkan analisis sebuah data masukan dianalisis oleh LIME yang menghasilkan prediksi probabilitas akhir sebesar 0.89 (89%) mengarah pada kategori Kurikulum_Akademik. Visualisasi bobot lokal menguraikan dinamika tarik-menarik probabilitas di dalam otak sistem. Di sisi kanan (diagram biru/hijau), keberadaan variabel mata (dengan bobot dorongan lokal sebesar 0.26) dan sks (bobot 0.12) berperan sebagai jangkar fundamental yang menarik prediksi menuju kategori Kurikulum. Sebaliknya, tidak ditemukannya fitur skripsi, cara, maupun pustaka di dalam kalimat masukan tersebut bertindak sebagai gaya penolak yang menghindarkan sistem dari kesalahan prediksi mengarah ke *Pedoman_Tugas_Akhir*. Penjabaran saintifik ini membuktikan validitas dan kewarasan (*sanity check*) logika internal sistem.

5.2. Implementasi Sistem Berbasis Cloud dan Antarmuka Pengguna (UI)

Produk akhir dari seluruh proses analisis data (*data pipeline*) adalah sebuah perangkat lunak interaktif. Modul prapemrosesan (*preprocessing.pkl*), objek representasi ruang vektor, dan model *Machine Learning* final (*best_model.pkl*) dienkapsulasi menggunakan protokol *Serialization (Pickle)*. Seluruh modul tersebut kemudian dirangkai ke dalam skrip antarmuka pengguna berbasis bahasa pemrograman Python menggunakan *framework* Streamlit.

Untuk menjamin aksesibilitas berkesinambungan tanpa hambatan dependensi lokal, sistem ini telah dikelola versinya menggunakan Git dan didistribusikan (*deployed*) ke peladen awan (*cloud server*) pada ekosistem Streamlit Community Cloud.



Berdasarkan implementasi antarmuka yang ditunjukkan pada Gambar di atas, sistem dirancang dengan prinsip *user-centric*. Pengguna akhir tidak perlu memahami kompleksitas arsitektur XGBoost maupun ekstraksi fitur TF-IDF yang berjalan di latar belakang. Pengguna hanya perlu mengakses tautan URL (*Uniform Resource Locator*) pada peramban (*web browser*) standar, mengetikkan pertanyaan pada kolom teks yang disediakan, dan sistem akan langsung memicu fungsi inferensi secara *real-time* untuk menampilkan rujukan dokumen pedoman yang paling akurat.

BAB VI

KESIMPULAN DAN REKOMENDASI

6.1. Kesimpulan Akhir Pengembangan penelitian *Capstone Smart Assistant* FAQ di lingkungan STMKG telah membuktikan hipotesis bahwa otomasi ekstraksi *intent* berbasis teks sangat layak diimplementasikan. Integrasi linier antara normalisasi leksikal, kuantifikasi TF-IDF, dan arsitektur *gradient boosting* pada XGBoost mampu menyelesaikan masalah klasifikasi multikelas dengan akurasi 82.60% dan kapabilitas pemisahan antar kelas (ROC-AUC) di atas 92%. Validasi tambahan menggunakan *Explainable AI* (LIME) secara meyakinkan mendemonstrasikan bahwa pengambilan keputusan sistem didasari oleh parameter morfologis kata kunci yang sangat masuk akal secara semantik.

6.2. Rekomendasi Pengembangan Berkelanjutan Demi pencapaian tingkat inteligensi yang lebih komprehensif pada fase pengembangan di masa depan (*future works*), diusulkan serangkaian rekomendasi taktis:

1. Ekspansi Diversifikasi Dataset: Menerapkan teknik *Data Augmentation* secara sintetis untuk menggandakan jumlah observasi pada kelompok *Training Data*, guna melatih ketahanan model terhadap berbagai variasi dialek, singkatan *slang*, atau kesalahan pengetikan ortografis (*typos*) dari pengguna.
2. Pemodelan Vektor Semantik (Word Embeddings): Menggeser paradigma ekstraksi ruang diskrit pada TF-IDF menjadi pendekatan *dense vector* berbasis jaringan saraf tiruan (seperti *Word2Vec*, *FastText*, atau model *Transformer-based* seperti IndoBERT). Model berbasis sekuensial ini memiliki memori jangka panjang untuk memahami relasi urutan kata dan konteks intonasi, bukan sebatas menghitung frekuensi terisolasi.

REFERENSI

1. Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794). Association for Computing Machinery.
2. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "*Why Should I Trust You?*": *Explaining the Predictions of Any Classifier*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 1135-1144). Association for Computing Machinery.
3. Salton, G., & Buckley, C. (1988). *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 24(5), 513-523.
4. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.